

Aplicação de Distribuições de Probabilidade na Previsão do Desemprego: Uma Abordagem Detalhada

Luiz Tiago Wilcke

6 de fevereiro de 2025

Resumo

Este artigo apresenta uma abordagem detalhada para a previsão da taxa de desemprego utilizando distribuições de probabilidade. São expostos os fundamentos teóricos, como o Teorema Central do Limite (TCL) e propriedades dos estimadores obtidos por Máxima Verossimilhança (MLE), com demonstrações e justificativas rigorosas. Em seguida, constrói-se um modelo probabilístico baseado na distribuição normal e apresenta-se o passo a passo para a estimação dos parâmetros e a construção de intervalos de confiança, demonstrando a aplicação prática dos conceitos teóricos.

1 Introdução

A previsão de indicadores econômicos, como a taxa de desemprego, é fundamental para a tomada de decisões em políticas públicas e estratégias empresariais. Um método comumente utilizado é modelar esses indicadores por meio de variáveis aleatórias e suas respectivas distribuições de probabilidade. Neste trabalho, supomos que a taxa de desemprego pode ser modelada por uma distribuição normal, justificando essa escolha com base em resultados teóricos e na agregação de múltiplos fatores independentes.

Para fundamentar a aplicação desta abordagem, detalharemos:

- Os fundamentos teóricos, com ênfase no Teorema Central do Limite (TCL) e nas propriedades dos estimadores;
- A construção do modelo probabilístico;
- A estimação dos parâmetros μ (média) e σ^2 (variância) via Máxima Verossimilhança;
- A criação de intervalos de confiança e a aplicação prática para a previsão do desemprego.

2 Fundamentação Teórica e Demonstrações

2.1 Modelagem com Distribuição Normal

Assumimos que a taxa de desemprego em um determinado período é representada por uma variável aleatória X que segue uma distribuição normal:

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

Aqui, μ indica o valor médio esperado (tendência central) e σ^2 mede a variabilidade dos dados.

2.2 O Teorema Central do Limite (TCL)

Sejam X_1, X_2, \dots, X_n variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) com

$$E[X_i] = \mu \quad \text{e} \quad \text{Var}(X_i) = \sigma^2 < \infty.$$

A média amostral

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

satisfaz:

$$\sqrt{n} \left(\frac{\bar{X}_n - \mu}{\sigma} \right) \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{quando } n \rightarrow \infty.$$

Demonstração Esquemática do TCL

1. **Centralização e Escalonamento:** Considere a soma $S_n = \sum_{i=1}^n X_i$. Temos:

$$E[S_n] = n\mu \quad \text{e} \quad \text{Var}(S_n) = n\sigma^2.$$

Assim, a média amostral \bar{X}_n possui:

$$E[\bar{X}_n] = \mu \quad \text{e} \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

2. **Construção da Estatística Padronizada:** Defina:

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}.$$

O TCL garante que, para n grande, Z_n se aproxima de uma distribuição normal padrão $\mathcal{N}(0, 1)$.

3. **Conclusão:** Mesmo que os X_i não sejam normalmente distribuídos, a média amostral, devidamente centralizada e escalonada, se comporta como uma normal para n suficientemente grande. Isso justifica o uso de métodos de inferência baseados na normalidade.

2.3 Estimação dos Parâmetros via Máxima Verossimilhança (MLE)

Dada uma amostra x_1, x_2, \dots, x_n da taxa de desemprego, o objetivo é estimar os parâmetros μ e σ^2 .

Função de Densidade da Normal

A função densidade de probabilidade para $X \sim \mathcal{N}(\mu, \sigma^2)$ é:

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right).$$

Função de Verossimilhança

A função de verossimilhança para os dados é:

$$L(\mu, \sigma^2; x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right).$$

Trabalha-se, então, com o logaritmo da função de verossimilhança:

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Obtendo os Estimadores MLE

1. **Estimador de μ :** Derivando $\ell(\mu, \sigma^2)$ em relação a μ e igualando a zero:

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0,$$

obtem-se:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i.$$

2. **Estimador de σ^2 :** Derivando em relação a σ^2 :

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0,$$

resulta em:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2.$$

(Observação: Para obtenção de um estimador insesgado, pode-se usar $\frac{1}{n-1}$, porém o MLE utiliza $\frac{1}{n}$.)

Propriedades dos Estimadores

Sob condições regulares:

- **Consistência:** Os estimadores $\hat{\mu}$ e $\hat{\sigma}^2$ convergem em probabilidade para μ e σ^2 , respectivamente, à medida que $n \rightarrow \infty$.
- **Normalidade Assintótica:** Temos

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}(0, I(\theta)^{-1}),$$

onde $\theta = (\mu, \sigma^2)$ e $I(\theta)$ é a informação de Fisher.

3 Metodologia Aplicada à Previsão do Desemprego

3.1 Coleta e Preparação dos Dados

Suponha que foram coletados dados históricos mensais da taxa de desemprego, totalizando n observações:

$$\{x_1, x_2, \dots, x_n\}.$$

Observações importantes:

- **Independência:** Assume-se que os dados são aproximadamente independentes. Caso haja autocorrelação (comum em séries temporais), pode ser necessário ajustar o modelo (por exemplo, utilizando modelos ARIMA).
- **Normalidade:** Mesmo que os dados individuais não sigam exatamente uma distribuição normal, o TCL justifica a aproximação para a média ou, em modelos agregados, a normalidade dos estimadores.

3.2 Estimação dos Parâmetros

1. Cálculo da Média Amostral:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Este valor representa a tendência central da taxa de desemprego e pode ser utilizado como previsão pontual.

2. Cálculo da Variância Amostral (MLE):

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2.$$

3. Validação dos Pressupostos:

- **Teste de Normalidade:** Aplicar testes (por exemplo, Shapiro-Wilk) e inspecionar gráficos Q-Q para verificar a adequação da hipótese de normalidade.
- **Análise de Resíduos:** Em modelos de séries temporais, verificar se os resíduos não apresentam autocorrelação significativa.

3.3 Construção de Intervalos de Confiança

Para quantificar a incerteza da previsão, constrói-se um intervalo de confiança para a média. Considerando que, para n grande,

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

utiliza-se o estimador $\hat{\sigma}$ para obter:

$$\text{IC para } \mu : \quad \hat{\mu} \pm z_{\alpha/2} \cdot \frac{\hat{\sigma}}{\sqrt{n}},$$

onde $z_{\alpha/2}$ é o quantil da normal padrão correspondente ao nível de confiança desejado (por exemplo, $z_{0.025} \approx 1,96$ para 95% de confiança).

3.4 Previsão e Aplicação Prática

1. **Previsão Pontual:** A estimativa $\hat{\mu}$ é utilizada como a previsão da taxa de desemprego para o próximo período.
2. **Intervalo de Confiança:** O intervalo fornece a margem de erro associada à previsão.
3. **Exemplo Numérico:** Suponha que, com $n = 120$ observações, os cálculos forneçam:
 - $\hat{\mu} = 8\%$;
 - $\hat{\sigma} = 1.2\%$.

O intervalo de confiança de 95% é:

$$\text{IC} = 8\% \pm 1,96 \cdot \frac{1.2\%}{\sqrt{120}}.$$

Realizando o cálculo:

$$\frac{1.2\%}{\sqrt{120}} \approx 0.1095\% \quad \Rightarrow \quad \text{IC} \approx 8\% \pm 0.2146\%.$$

Assim, o intervalo de confiança é aproximadamente $[7.79\%, 8.21\%]$.

4 Demonstração dos Teoremas e Propriedades dos Estimadores

4.1 Normalidade Assintótica do Estimador $\hat{\mu}$

Definindo a média amostral:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad \text{com } E[X_i] = \mu \text{ e } Var(X_i) = \sigma^2,$$

aplicamos o TCL, que garante:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1),$$

ou seja,

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{para } n \text{ grande.}$$

4.2 Consistência e Normalidade Assintótica dos Estimadores MLE

1. **Consistência:** Sob condições de regularidade (identificação única do parâmetro, existência de momentos, etc.), os estimadores $\hat{\theta}$ com $\theta = (\mu, \sigma^2)$ satisfazem:

$$\hat{\theta} \xrightarrow{p} \theta \quad \text{quando } n \rightarrow \infty.$$

2. **Normalidade Assintótica:** Utilizando uma expansão de Taylor da log-verossimilhança em torno de θ e aplicando o teorema de Slutsky, obtém-se:

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}(0, I(\theta)^{-1}),$$

onde $I(\theta)$ é a informação de Fisher definida por:

$$I(\theta) = -E \left[\frac{\partial^2 \ell(\theta; X_1, \dots, X_n)}{\partial \theta \partial \theta^\top} \right].$$

5 Conclusão

A aplicação de distribuições de probabilidade, especialmente a distribuição normal, para a previsão da taxa de desemprego está bem fundamentada teoricamente. Por meio do Teorema Central do Limite, asseguramos que a média amostral se aproxima de uma distribuição normal para amostras grandes, mesmo que os dados individuais não sejam exatamente normais. Ademais, o método de Máxima Verossimilhança fornece estimadores consistentes e, sob condições regulares, normalmente distribuídos assintoticamente, permitindo a construção de intervalos de confiança e a realização de testes de hipóteses.

Esta abordagem detalhada demonstra tanto a aplicação prática quanto os fundamentos teóricos que garantem a validade dos métodos de previsão, proporcionando uma ferramenta robusta para a análise de indicadores econômicos, como a taxa de desemprego.